

Tamweel Lite: هل نحتاج تجميع نماذج لإشارات المراجعة (Review flag)؟

مشروع تعليمي على بيانات اصطناعية، ولا يُستخدم لقرارات تمويل فعلية

القرار الذي يدعمه المشروع

اختيار نموذج يرفع إشارة مراجعة للطلبات المرجح تعثرها خلال 90 يومًا بعد الطلب، والحكم هل يستحق تجميع النماذج تعقيده أم نكتفي بنموذج واحد.

معياري النجاح

نربط متوسط الدقة (AP, Average Percision) والمعايرة (Calibration) بالخسارة التعليمية $(10 \times FN + FP)$ وبسعة مراجعة 12% من الطلبات في كل فترة.

22

خاصية متاحة وقت الطلب

12%

سقف المراجعة لكل فترة

90 يومًا

مدى التعثر بعد الطلب

تقسيم يمنع التسرب (Leakage)

كل خطوة تتعلم من بيانات لم تر الاختبار

الفصل

تقسيم زمني أمامي (Forward time-based split) ، مع فصل العملاء بين التدريب والتحقق، وانتظار 90 يومًا حتى تكتمل فترة الخصائص (Features).
استبعدنا حقلين لا يُعرفان وقت الطلب، وهما: `collection_calls` & `days_past_due_60`


أين يتعلم كل جزء؟

أوزان التجميع (Ensemble weights) والمُجمع (stacker) تتعلَّم على OOF داخلي فقط.
المعايرة تمت على فترة محجوزة (يوليو – سبتمبر 2024)، ثم يُجمَّد المعايير (Calibrator) والعتبة (Threshold) قبل التنبؤ على التحدي.



القرار (Logistic Regression) : KEEP SINGLE

لم يتفوق أي تجميع على الانحدار اللوجستي (Logistic Regression) بأكثر من الانحراف المعياري للطيات (Folds SD) البالغ 0.0298، كما زاد التكديس (Stacking) خطأ المعايرة المتوقع (Expected Calibration Error, ECE) بمقدار 0.0122.



النماذج	AP	الفرق عن Logistic
Logistic	0.3917	—
Weighted	0.3894	– 0.0022
Stack	0.3832	– 0.0085
Equal	0.3717	– 0.0200

السعة (Capacity) 12%



طبقت مرة واحدة على 2,500 طلب: كان 330 طلبًا فوق العتبة (Threshold) = 0.1223، فُرِغَتْ منها 300 إشارة مراجعة.

الخسارة الافتراضية (Simulated loss)

الخسارة = 10 × عدد السالب الكاذب (False Negative, FN) + عدد الموجب الكاذب (False Positive, FP)، وهي وحدات تعليمية وليست ربالات فعلية.

منحنى الموثوقية: نموذج اليوم الرابع (LightGBM) موزون

نقطة واحدة: المعايرة والتفسير يخصان نموذجًا محددًا وعينة محددة



ماذا يُظهر (1,733 صف، 139 موجبًا)؟

الاحتمال الخام (Raw Prediction) يقع تحت خط التطابق، أي أنه يبالغ في التقدير.

(Sigmoid calibration) تقرّبه من الخط، فتنخفض درجة براير (Brier score) من 0.1130 إلى 0.0671. الترتيب لم يتغير، فمتوسط الدقة بقي 0.2587.

التفسير غير السببي (Non-causal interpretation)

الطلب TR-009585: الدرجة الخام (Raw Score) 0.9031 تقابل احتمالًا معيارًا 0.4795. أكبر مساهمتين: درجة مكتب الائتمان (bureau_score) بقيمة 2.2693، ونسبة الدين إلى الدخل (dti) بقيمة 1.1981.

الحدود (Limitations)

نقاط الاحتمال المعيار تنتهي قرب 0.45، فالمنطقة العالية غير مفحوصة. والنموذج النهائي هو الانحدار اللوجستي، ولم تؤثر (Sigmoid calibration): ارتفعت درجة براير (Brier Score) من 0.0765 إلى 0.0781، وارتفع خطأ المعايرة المتوقع من 0.0211 إلى 0.0349 على 836 صفًا. وهذا تشخيص على عينة التعلم.

البقاء على نموذج واحد، مع مراجعة قبل أي استخدام

نقطة واحدة: ما تدعمه النتائج وما يحتاج مراجعة

الرسالة التنفيذية ((Executive Message Summary))

الانحدار اللوجستي يكفي؛ متوسط الدقة له 0.3917 مقابل 0.3894 لأفضل تجميع. والعتبة المعاييرة 0.1223 ترفع 300 إشارة من 2,500 طلب ضمن السعة.

المتابعة لكل دفعة

حجم الإشارات مقابل 12%، وتوزيع الدرجات، و Brier و ECE على التسميات الناضجة، ومعدلات المناطق مع مقاماتها.

أهم قيدين

- 1 - البيانات اصطناعية والفترات الثلاث متداخلة، فالنتائج دليل تطوير وليست اختباراً نهائياً.
- 2 - فجوة معدل الإنذار الخاطئ (False Positive Rate, FPR) بين المناطق 3.98 نقطة (الشرقية 6.31% والغربية 10.29%) وتحتاج إلى مراجعة، وليست شهادة عدالة.

يتغير القرار لو تفوق التجميع على الانحدار اللوجستي (Logistic Regression) بأكثر من 0.0298 في متوسط الدقة مع بقاء خطأ المعاييرة المتوقع ضمن الحد. المرجع: [TAG: final , <https://github.com/AbdulazizAldhaayan/SDA-DSC-211-S06> Repository]